

# SZAKDOLGOZAT

**Snooker billiardjáték elemzése**

**Lengyel Márk**

Mérnökinformatikus BSc  
Mérnökinformatikus Szakirány

**2022**

# Tartalomjegyzék

<b>Ábrák jegyzéke</b>	<b>1</b>
<b>1. Bevezetés</b>	<b>2</b>
<b>2. A Snooker játék</b>	<b>3</b>
2.1. Általánosságban a snooker játékról . . . . .	3
2.2. Eszközök . . . . .	3
2.3. Pontszerzés . . . . .	3
<b>3. Felhasznált szoftverek</b>	<b>5</b>
3.1. Az OpenCV képfeldolgozási könyvtár . . . . .	5
3.2. Tensorflow gépi tanulási könyvtár . . . . .	5
<b>4. A program megtervezése</b>	<b>7</b>
4.1. Az asztal felismerése . . . . .	7
4.2. A golyók azonosítása . . . . .	9
4.2.1. Azonosítás mintaillesztéssel . . . . .	9
4.2.2. Azonosítás körkeresés és mintaillesztéssel . . . . .	11
4.2.3. Azonosítás körkeresés és gépi tanulás segítségével . . . . .	12
4.3. Analizálás . . . . .	13
<b>5. Megvalósítás</b>	<b>14</b>
5.1. Alkalmazott módszerek . . . . .	14
5.2. A golyók pozíciója . . . . .	14
5.2.1. A szükséges könyvtárak importálása . . . . .	14
5.2.2. Az asztal kontúrjának megkeresése . . . . .	14
5.2.3. Az asztal kivágása és torzítása . . . . .	19
5.2.4. Körkeresés és azonosítás . . . . .	21
<b>Irodalomjegyzék</b>	<b>23</b>

# Ábrák jegyzéke

2.1. A golyók kezdeti pozíciója. . . . .	4
4.1. Egy nyers bemeneti kép a játék ablakáról. . . . .	7
4.2. A 4.1 kép HSV re alakított verziója RGB reprezentációban. . . . .	8
4.3. A 4.1 kép a maszkolás után. . . . .	8
4.4. Az eredeti képből kinyert játékterület. . . . .	9
4.5. A mintaillesztéshez használt minta. . . . .	10
4.6. A zöld golyó mintaillesztésének hibája (bal) és annak orvoslása HSV konverzióval (jobb). . . . .	11
4.7. A barna golyó mintaillesztésének hibája (bal) és annak orvoslása a piros golyók levonásával (jobb). . . . .	11
4.8. A Hough transzformáció lefutása után kapott körök. . . . .	12
4.9. Az adatkészlet elemei. . . . .	13
4.10. A neurális hálózattal való golyófelismerés kimenete. . . . .	13
5.1. A Canny éldetektálás után kapott kép. . . . .	17
5.2. A felismert asztal kontúra a bináris képen, piros körvonallal keretezve. . . .	18
5.3. A felismert asztal négy pontból álló körvonala a bináris képen, piros körvonallal keretezve. . . . .	19

## 1. fejezet

# Bevezetés

A dokumentumban szereplő projekt célja snooker billiardjáték felismerése, és analizálása fénykép/képernyőfelvétel alapján. A felismerés az asztalon elhelyezkedő különböző színű golyók pozíciójának meghatározásából áll.

A felismerés megvalósításához különféle képfeldolgozási eszközöket, neurális hálózat alapú kép osztályozást használok, amelyeket **Python** programozási nyelven valósítok meg főként **OpenCV** és **Tensorflow** könyvtárak eszközeinek használatával.

A bevezetés későbbi részeiben ismertetem a snooker billiardjátékot, továbbá a projekt elkészítéséhez használt programozási nyelvet és fejlesztési könyvtárakat.

## 2. fejezet

# A Snooker játék

### 2.1. Általánosságban a snooker játékról

A snooker a billiárdjátékok egy bizonyos fajtája, amelyet egy zöld színű posztóval bevont asztalon játszanak, amelynek mérete általában 12 x 6 láb (365,8 cm x 182,9 cm)[18]. Az asztal négy sarkában és a két hosszabb oldal felénél ún. **zsebek** helyezkednek el. A játék célja a színes golyók belökése a fehér golyó segítségével a fent említett zsebekbe.

### 2.2. Eszközök

A játékot két fél játssza egymás ellen. A felek a lökéseiket egy hosszúkás, fából készült eszköz segítségével végzik. Ezt az eszközt **dákónak** nevezik. A dákó vége, amellyel a golyó elütésre kerül, bőrrel van bevonva, amely a golyóval való kapcsolatot javítja. A dákón kívül a golyó elütéséhez a játékosok használhatnak segédeszközöket.

A tartozékok részei továbbá a már eddig is szóba került golyók. A játékhoz **22 db színes golyó** tartozik amelyek átmérője 52,5 mm.[18]

Az egyes golyók különböző pontértékkal rendelkeznek:[18]

- 1 db fehér,
- 15 db piros (1 pont),
- 1 db sárga (2 pont),
- 1 db zöld (3 pont),
- 1 db barna (4 pont),
- 1 db kék (5 pont),
- 1 db rózsaszín (6 pont),
- 1 db fekete (7 pont).

A fehér golyó nem rendelkezik pontértékkel, mivel a játékosok ezt a golyót használják lökéseikhez.

A játék egy menetét **frémnek** nevezik, amely a kezdő lökéstől a fekete golyó elhelyezéséig tart.[18]

### 2.3. Pontszerzés

A játékosok a pontjaikat a golyók bizonyos sorrendben való zsebbe helyezésével szerzik. Az egymás után hiba nélkül szerzett pontok összegét **törésnek** nevezik. Egy játékos például szerzhet 9 pontos törést a következő golyók egymás utáni elhelyezésével *piros -> zöld -> piros -> barna*.[13]



**2.1. ábra.** A golyók kezdeti pozíciója.

Egy játékos büntetőpontokat kap hibák elkövetése esetén. Hibát elkövetni lehet például a fehér golyó zsebbe helyezésével, nem megfelelő színű golyó elütésével. Az elkövetett hibáért minimum 4, maximum 7 pontlevonás jár, attól függően, hogy milyen színű golyók mozdulnak a hiba elkövetésekor (pl.: Ha a cél a piros golyó lelökése, de a lövő a feketét találja el, akkor 7 hibapont jár). A hibát elkövető játékos a törésének pontjait megkapja a hibát elkövetett lövés közben elhelyezett golyók pontjainak kivételével.[18]

### 3. fejezet

## Felhasznált szoftverek

### 3.1. Az OpenCV képfeldolgozási könyvtár

Az OpenCV (Open Source Computer Vision Library) egy főként **valós idejű képfeldolgozáshoz** használt programozási függvénykönyvtár. A könyvtár többféle programozási nyelvhez készült implementációval létezik (pl.: C++, Python, Java stb. )[4], amelyek közül ebben a projektben a Python programozási nyelvhez készült verziót fogom használni. A szoftver szabadon használható az *Apache License 2.0* alatt.

A függvénykönyvtár fejlesztését az Intel Research kezdeményezte 1999-ben, a CPU intenzív alkalmazások fejlődése érdekében. A projekt lefőbb hozzájárulói az Intel Russia optimalizálással foglalkozó szakemberei, továbbá az Intel Performance Library csapata. [11]

Kezdetben az OpenCV létrehozásának célja volt, hogy **nyílt, optimalizált** kódot képezzen gépi látáshoz, valamint, hogy egy **egységes infrastruktúrát** biztosítson a fejlesztőknek a területen, ezzel megkönnyítve a programkódok olvashatóságát és terjesztőségét. Cél volt még, hogy fejlesszék a gépi látásra alapuló kereskedelmi felhasználást, hordozható, teljesítményorientált programkód létrehozásával.[5]

Az OpenCV-t sokféle területen használják, ezek közül néhány:

- arcfelismerő rendszerek,
- gesztusok felismerése,
- objektumok felismerése,
- szegmentálás és felismerés,
- mozgás felismerés,
- kiterjesztett valóság.

A dolgozat keretében a könyvtárból használt függvények segítségével kerülnek megnyitásra a képek, továbbá a képeken való műveletek (pl.: szürkeárnyalatolás, élkeresés) is a könyvtár segítségével lesznek végrehajtva. A későbbiekben lesz szó a könyvtárból használt függvényekről, azok működéséről nagyobb részletességen.

### 3.2. Tensorflow gépi tanulási könyvtár

A Tensorflow az OpenCV -hez hasonlóan egy függvénykönyvtár, amely a **neurális hálózatok elkészítését és betanítását** teszi lehetővé. A Tensorflow egy nyílt forráskódú szoftver könyvtár, használható különböző feladatok elvégzésére is, de főként mély neurális hálózatok betanítására és azokkal való következtetésekre, becslésekre használható. [1]

A Tensorflow a Google Brain csapat által lett kifejlesztve a Google saját kutatásaihoz. Az első verzió az *Apache License 2.0* szoftverlicensz alatt jelent meg, majd később 2019

szeptemberében megjelent a Tensorflow frissített verziója, amelyet Tensorflow 2.0nak neveztek el.[1]

A könyvtár használható különböző programozási nyelvekben is (Python, C++, Javascript, stb.) amelynek köszönhetően flexibilisen használható különféle alkalmazásokban. A Tensorflow sokfélé funkcióval rendelkezik, ezek közül a következőkben néhányat részletesen megemlítek.

A Tensorflow funkciói közé tartozik, hogy támogatja az **automatikus differenciálás** (Automatic differentiation) folyamatát, amellyel automatikusan kiszámolható a gradiens vektor egy modelhez, annak paramétereit figyelembe véve. Ez a folyamat különösen hasznos a visszaterjesztéses (Backpropagation) modelleknek, ahol gradiensekre van szükség az optimalizáláshoz. Ahhoz, hogy ez megvalósítható legyen a keretrendszer számon tartja a modell bemenetére végzett műveleteket, majd a modell paramétereitől függően kiszámolja a gradienseket. [1, 10]

A könyvtár lehetővé teszi továbbá, a számítások **elosztását** különböző hardver eszközök között, ezzel a tanítás és kiértékelés folyamatok nagymértékben felgyorsíthatóak főként komplex, több rétegű modellek esetén.[1]

A modellek tanításához nélkülözhetetlen a **költségfüggvények használata**, ezek rendelkezésre állnak a könyvtárban. A költségfüggvények szerepe, hogy kiszámolják a "hibát", vagy másnéven eltérést a modell kimenete, és annak az adott bemenethez tartozó elvárt kimenete között, amely érték segítségével a modell hangolni tudja paramétereit.

A Tensorflow könyvtárban megtalálható egy ún. `tf.nn` modul, amelynek segítségével egyszerű műveletek végezhetők neurális hálózatokon. Ilyen műveletek lehetnek konvolúciók képfelismeréshez, aktivációs függvények (Softmax, RELU, Sigmoid, stb.) és egyéb primitív műveletek.

A könyvtár részét képezik különböző **optimalizálók**, amelyek a modellek betanításában játszanak szerepet, különböző optimalizálók lehetővé teszik a paraméterek különféle módon való hangolását, ezzel kihatva a modell teljesítményére. Az ilyen optimalizálók közül az egyik legismertebb az *ADAM Optimizer*, amelyet ebben a munkában is felhasználunk.

Neurális hálózatok közül főként **konvolúciós neurális hálózatokat** (Convolutional Neural Network) fogok használni a későbbiekben, amelyek a képfeldolgozás, kép osztályozás területén teljesítenek kiemelkedően. A könyvtár egyes eszközeiről szintén részletesebben beszélek majd a megvalósítással kapcsolatos fejezetben.

## 4. fejezet

# A program megtervezése

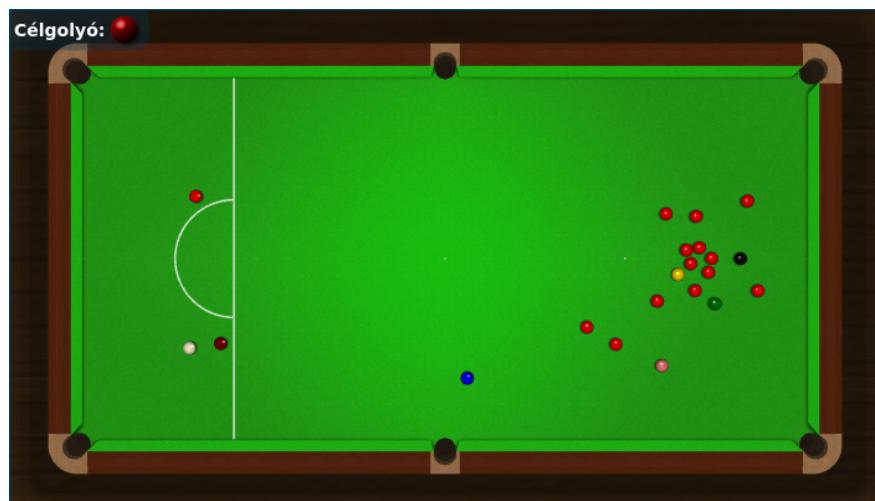
### 4.1. Az asztal felismerése

Ebben az alfejezetben a program első folyamatáról lesz szó, ami nem más mint az asztal, vagy más néven játékterület felismerése. A program ezen része bemenetként fog fogadni egy képet. Ez a kép származhat **videófelvételből** (videófelvétel egy képkockája), **valós idejű felvételből** (szintén egy képkocka), vagy szimplán egy **képfájlból**. A program készítése közben egy valósághű internetes snooker játékról[8] készített felvételeket fogok használni a felismeréshez. A videójátékból származó felvétel azonban bizonyos szempontokból eltér a valóságtól, ezekről később lesz szó, de lényegében jól használható a felismerés elkészítéséhez, továbbá megkönnyíti a tesztelést és a felvételek beszerzését.

Az asztalfelismerő lépés kicsit elkülönül a többi lépéstől, hiszen a további lépések különféle bemenetszerzési módszerektől függetlenül, megegyezően hajtódnak végre. Ahhoz hogy a további lépések pontosak legyenek és megfelelő teljesítménnyel működjenekek, az asztalt mindenkor mindenkorának kell felismerni.

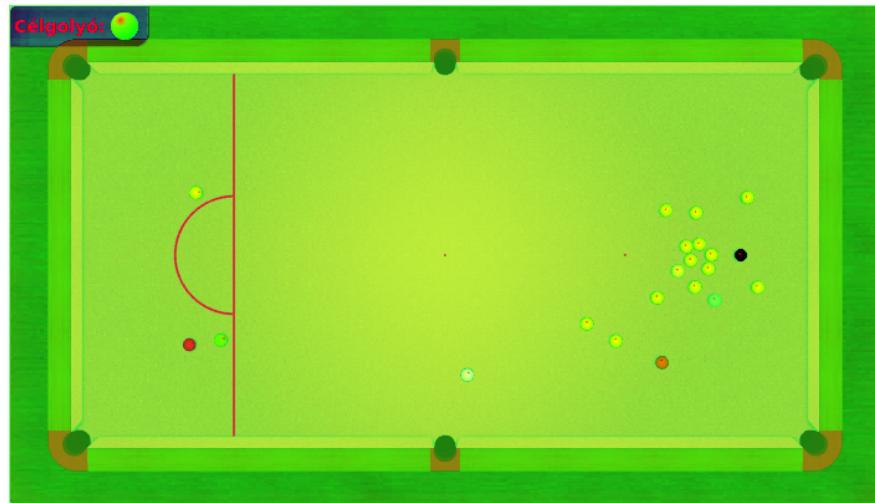
Ebben a módszerben az elforgatást leszámítva a detektálás, átméretezés és a torzítás lesz középpontban. Az elforgatást nem veszem figyelembe, hiszen a bemenetről feltételezhető, hogy bizonyos orientációban áll rendelkezésre.

A valódi bemeneti kép, függetlenül annak előállítási módszerétől, a 4.1 képen látható.



4.1. ábra. Egy nyers bemeneti kép a játék ablakáról.

Ezen a képen kell megtalálni a játékterület zöld részét. Ez könnyen megtehető a kép ún. HSV (Hue Saturation Value) formátumra való átalakításával. Ennek a konverziónak a kimenete a 4.2 képen látható.



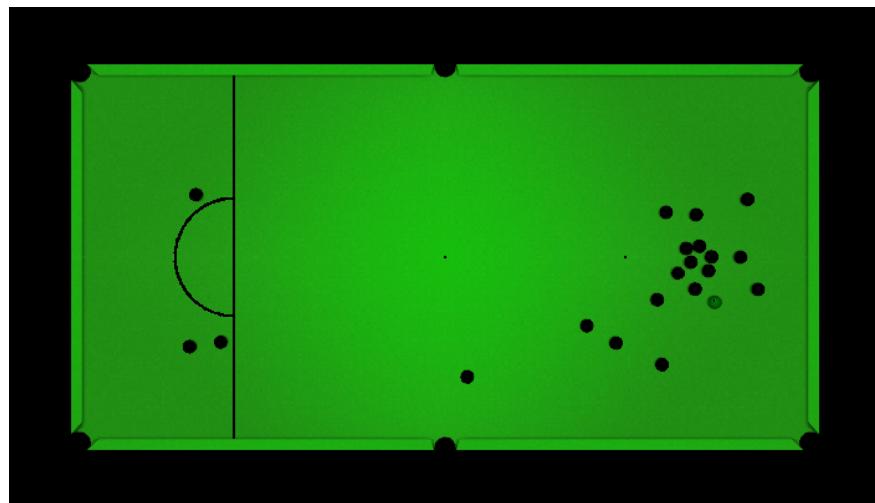
**4.2. ábra.** A 4.1 kép HSV re alakított verziója RGB reprezentációban.

Ez az átalakítás azért fontos, mert HSV formátumban könnyebben intervallumok közé lehet szorítani a játékterület zöld színét. A HSV konverzió belső működéséről részletesebben a megvalósítás részben lesz szó.

A HSV konverzió során kapott intervallumok:

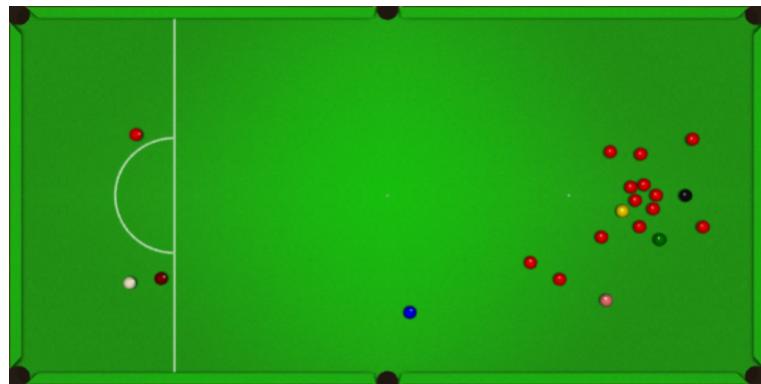
- árnyalat (Hue),
- telítettség (Saturation),
- érték (Value).

A HSV konverzió után az adott specifikus intervallumon kívül helyezkedő értékek maszkolásra kerülnek, hátrahagyva a kívánt játékterület képpontjait. A kép a maszkolás után visszaalakításra kerül az eredeti RGB formátumára. A folyamat után kapott kép a 4.3 képen látható.



**4.3. ábra.** A 4.1 kép a maszkolás után.

Az előző folyamat után már jól látható a játékterület, azonban vannak apró foltok amik nem kerültek maszkolásra. Ezek a foltok hasonló HSV értékekkel rendelkeznek, mint a játékterület, kiszűrésük megoldható a kontúrok megkeresésével, majd feltételezve, hogy a legnagyobb folt a maszkolt képen a játékterület, annak kiválasztásával. Ezzel az eljárással már megadható a játékterület kontúrja. Szintén feltételezve, hogy ez négy sarokpontból áll, és egy téglalap pontosan határolja, a játékterület képe 4.4 megkapható a kontúr eredeti képből való kivágásával és átméretezésével.



**4.4. ábra.** Az eredeti képből kinyert játékterület.

Fent említettem, hogy feltételezhető, hogy a játékterület kontúrja a kontúrkeresés után téglalap alakú, és a kontúrt alkotó pontok száma 4. Viszont valóságban ez nehezen fordul elő, ezért szükséges a pontok számának leszűkítése és a négy pontot határoló alakzatban lévő kép torzítása 2:1 oldalarányú téglalapra. Az oldalarány a szabvány snookerasztal 12 x 6 láb (365,8 cm x 182,9 cm)[18] méretéből következik. A pontok szűkítéséről és a torzításról a megvalósítás fejezetben lesz részletesebben szó.

## 4.2. A golyók azonosítása

A golyók azonosítását különféle módszerekkel lehet elvégezni, ezek eltérnek sebességen és pontosságban. A folyamatok bemenete az előzőekben megismert asztal felismerés kimenete lesz, kimenetük pedig a 4.1 táblázatban látható x és y pozíciók, adott golyók színe szerint. A folyamat belső működése módszerenként eltér egymástól, ezeket a módszereket az implementáció egyes iterációjának részeként használtam, majd változtattam meg az elért teljesítmény növeléséhez.

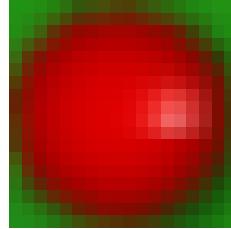
### 4.2.1. Azonosítás mintaillesztéssel

Ennek a módszernek az alapja tisztán mintaillesztéssel működik. A mintaillesztés egy arányos méretű képet illeszt rá a játékterület képére, majd amennyiben az illeszkedés mértéke meghalad egy bizonyos küszöbértéket, a mintaillesztés iterációjának a pozíciója mentésre kerül. Ebből a pozícióból meghatározható a golyó helyzete. A mintaillesztéshez használt minta a 4.5 ábrán látható.

A 4.5 minta felbontása láthatóan alacsony, azonban túl nagy felbontás esetén a folyamat meglehetősen lassabban megy végbe, továbbá a minta méretét még a felismert játékterület mérete is meghatározza.

**4.1. táblázat.** A golyó felismerés kimeneti adatai a 4.4 kép alapján.

golyó színe	x pozíció [0, 1023]	y pozíció [0, 511]
black	914	256
blue	542	414
brown	206	368
green	880	316
pink	808	398
red	744	368
red	172	174
red	846	262
red	706	346
red	854	200
red	874	256
red	924	180
red	802	312
red	814	196
red	840	244
red	938	298
red	870	274
red	858	240
red	854	298
white	162	374
yellow	830	276



**4.5. ábra.** A mintaillesztéshez használt minta.

A mintaillesztés ún. Kereszt Korrelációval (Normed Cross Correlation) megy végbe, ez a 4.1 képletben látható[11, 12].

$$R(x, y) = \frac{\sum_{x',y'}(T(x', y') \cdot I(x + x', y + y'))}{\sqrt{\sum_{x',y'} T(x', y')^2 \cdot \sum_{x',y'} I(x + x', y + y')^2}} \quad (4.1)$$

A képletben az  $x$  és  $y$  az eredeti képen vizsgált terület bal felső sarkát,  $x'$  és  $y'$  a minta képnek az adott képpontját,  $T$  a minta képet és  $I$  az eredeti képet jelöli.

A mintaillesztés problémái közé tartozik, hogy a zöld golyó mintaillesztésénél a küszöbértéket beállítani nehéz, és az eredmény pontatlan, lásd 4.6.

A 4.6 ábrán látható hiba valamelyest orvosolható a kép és minta HSV -re való konvertálásával. Ez a konverzió jó eredményeket ad, azonban nagyon minimálisan csökkenti a teljesítményt. A mintaillesztés sajnos prolémákba ütközik a piros és barna golyók megkülönböztetésekor is. Ez a 4.7 képen látható.

Itt a színek közelsége miatt nehéz megkülönböztetni a golyókat, ezért a piros és barna golyók nagyon minimálisan térnek el a 4.1 függvény miatt. Ez a probléma HSV konvertálás után is fennáll. Erre a megoldás, hogy az érzékelt piros golyók kivonásra kerülnek a barna golyók listájából. Ahhoz, hogy pontos legyen az eredmény, viszont szükséges, hogy a piros golyók megfelelően legyenek érzékelve, amely nem minden esetben biztosítható, ezért ez



**4.6. ábra.** A zöld golyó mintaillesztésének hibája (bal) és annak orvoslása HSV konverzióval (jobb).



**4.7. ábra.** A barna golyó mintaillesztésének hibája (bal) és annak orvoslása a piros golyók levonásával (jobb).

a módszer nem túl pontos bizonyos bemenetekre. Hasonló problémák merülhetnek fel a piros és rózsaszín, továbbá a fehér és rózsaszín golyók felismerésekor is.

Annak ellenére, hogy a módszer nem túl optimális, jól használható adatkészletek készítésére, hiszen a felsmerést nagyrészt helyesen megoldja és a problémák ismeretében a kézzel válogatást nagymértékben megkönyíti.

#### 4.2.2. Azonosítás körkeresés és mintaillesztéssel

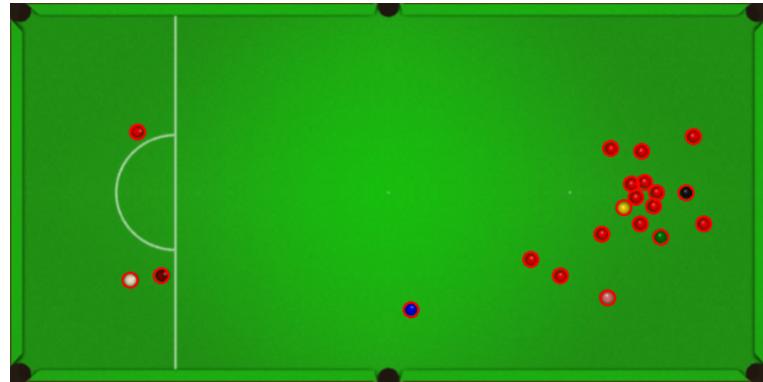
Az előző módszerhez hasonlóan a golyó színek szerinti osztályozása itt is mintaillesztéssel történik, azonban a sebesség növelése érdekében először a golyók helyzetét egy kördektáló algoritmus határozza meg, majd a kapott értékek jutnak tovább a mintaillesztő algoritmushoz. Ez az egész képen való pásztázás és mintaillesztéshez képest a teljesítményt a minták leszűkített mennyiségenek köszönhetően nagymértékben növeli.

A körök megtalálásához a körkereső algoritmusnak meg kell adni néhány paramétert, ezek közé tartoznak:

- a keresett körök minimális és maximális sugara,
- a keresett körök közti minimális távolság, duplikációk szűréséhez,
- az ellenőrzött alakzatok körrel való hasonlóságának küszöbértéke.

Az algoritmus lefutás után megadja a bemeneti játékterületen talált kör alakú kontúrokat, ezeket a 4.8 ábra szemlélteti. A körkereső algoritmusról a megvalósítás fejezetben írok részletesebben.

Ez a módszer körök megtalálására jól használható, a mintaillesztéshez szükséges képek könnyedén kivághatók az eredeti képből a körök paraméterei alapján. A probléma szintén a mintaillesztéssel van, hiszen a kivágott körök az előzőleg megismert mintaillesztéssel kerülnek beazonosításra. Ez sajnos az eddig megismert hibákat vonja maga után, annak



**4.8. ábra.** A Hough transzformáció lefutása után kapott körök.

ellenére, hogy a sebesség javul. Viszont akárcsak a szimpla mintaillesztéses módszer ez a módszer is alkalmas adatkészletek elkészítésére, és a kapott adatok kézzel ellenőrzését nagymértékben megkönnyíti.

#### 4.2.3. Azonosítás körkeresés és gépi tanulás segítségével

A mintaillesztés hibáinak kiküszöböléséhez, az osztályozás elvégezhető neurális hálózat segítségével. Ez a játékterület egy kerettel való képpontonkénti végigpásztázásával szintén megoldható, azomban körkeresésnél megismert Hough transzformációval jobb teljesítmény érhető el.

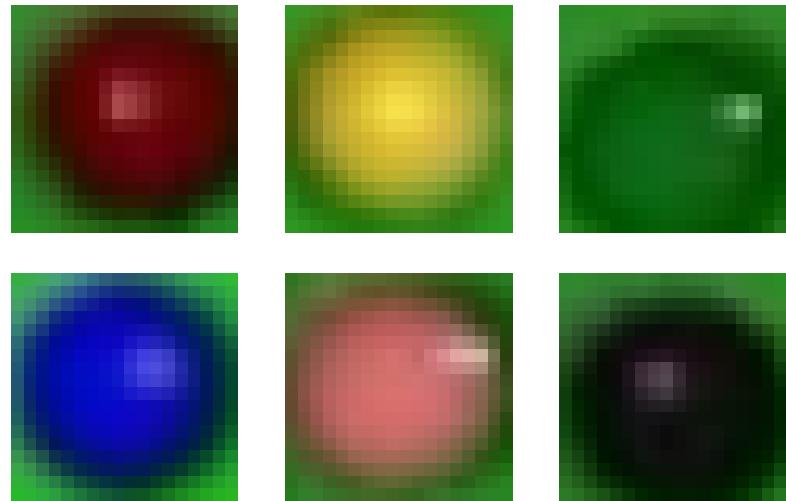
A következőkben a körkeresés eredményeképp kapott, a bemeneti játékterület képéből kivágott golyók osztályozásáról lesz szó neurális hálózat segítségével. A kivágott képek fogják a bemenetet képezni, majd a neurális hálózat azt osztályozza egy 0 tól 7 ig terjedő egész számként. Ezek a számok a golyók színeit reprezentálják, lásd 4.2 táblázat.

**4.2. táblázat.** A golyók szín szerint, és azok azonosítói.

Golyó színe	Azonosító
fekete	0
kék	1
barna	2
zöld	3
rózsaszín	4
piros	5
fehér	6
sárga	7

A neurális hálózat betanításához szükség van betanítási adatkészletre, viszont az előzőekben megsimert módszereknél szóba került, hogy viszonylag kevés kézi szortírozással könnyedén lehet velük előállítani adatkészletet, amely tökéletes a neurális hálózat betanításához és teszteléséhez. Az adatkészlet néhány eleme a 4.9 ábrán látható.

A betöltött adatok címkével megfelelően azonosítva átadásra kerülnek a neurális hálózatnak. Ahhoz, hogy a tanítás jó eredményeket hozzon, gondoskodni kell arról, hogy a betanítási adatok között egyenlő arányban szerepelnek az egyes golyók színek szerint, továbbá, hogy az adatkészlet elemei megfelelően össze vannak keverve. Az előkészített adatkészlet egy kis része (10% - 30%) elkülönítésre kerül, amely a neurális hálózat pontosságának tesztelésére fog szolgálni.



**4.9. ábra.** Az adatkészlet elemei.

A betanítási folyamatok után a neurális hálózat mentésre kerül, így az későbbi kívánt használatba vétel esetén egyszerűen betölthető, a tanítás és felhasználás külön programfájlokban könnyedén elvégezhető.

A körfelismerés módszerrel ötvözve, a neurális hálózattal való osztályozás gyors és pontos eredményeket biztosít. A felismerés egy kimenetele a 4.10 képen látható.



**4.10. ábra.** A neurális hálózattal való golyófelismerés kimenete.

A módszer eredményességének köszönhetően későbbiekbén részletesebben ismertetem a megvalósítás fejezetben.

### 4.3. Analizálás

## 5. fejezet

# Megvalósítás

### 5.1. Alkalmazott módszerek

A megvalósítás során az eddig megismert módszereket fogom felhasználni, azokat Python programozási nyelven fogom elkészíteni és ismertetni. Az egyes algoritmusokat függvények formájában készítem el, ezeket a függvényeket pedig több Python szkriptben is felhasználom.

Az eddig megismert módszerek közül elsősorban a nyers bemenetből emelem ki a játékterületet, ezt követően a golyók pozíciójának felismeréséhez kör detektálást és egy neurális hálózatot fogok használni. A neurális hálózat betanításához az adatkészletet kör detektálással, mintaillesztéssel és kézi válogatással fogom elkészíteni. A következőkben az egyes függvények működését, azokban felhasznált külső könyvtárak eszközeit ismertetem részleteiben.

A fejezetek felosztása az eddig megismert lépések szerint kerül rendezésre.

### 5.2. A golyók pozíciója

#### 5.2.1. A szükséges könyvtárak importálása

Ahhoz hogy a függvények megfeleően működjenek, meg kell mondani a programnak, hogy használja a külső könyvtárakat.

Ez a 5.1 kódSOROK alapján tehető meg.

```
1 import math  
2 import numpy as np  
3 import cv2
```

#### 5.1. kódRészlet. Könyvtárak importálása.

A `math` könyvtár segítségével matematikai műveleteket (gyökvonás, szinusz, koszinusz) lehet végezni, a `numpy` könyvtár a tömbök, mátrixok kezelését, azokkal való műveleteket segíti és gyorsítja, a `cv2` pedig az OpenCV eszközeit teszi elérhetővé.

#### 5.2.2. Az asztal kontúrjának megkeresése

A nyers képből a játékterület megszerzéséhez azt először be kell tölteni egy többdimenziós tömbbe. A kép betöltése többféleképp végbemehet, ezért ezt konkrétan nem részletezem.

A betöltött kép tömbjének alakja megegyezik a kép szélességével és magasságával, továbbá az intenzitási értékekkel, tehát egy 1024 x 512 méretű RGB képet betöltve, annak tömbjének az első és második dimenziója 1024 és 512, a harmadik pedig az RGB (Piros, Zöld, Kék) intenzitásoknak megfelelően 3 méretű.

Fontos megjegyezni, hogy az OpenCV a képeket betöltéskor BGR formátumban tölti be, ez az elnevezésből adódóan annyiban tér el az RGB formátumtól, hogy a piros (R) és kék (B) színcsatornák fel vannak cserélve.

A nyers bemeneti kép megszerzése után következik az asztal kontúrjának megkeresése. Első lépésként a képet HSV formátumra kell alakítani, majd az alsó és felső intenzitási értékhatarok megadásával meghatározható a maszk, amely alkalmazható az eredeti képre. A fentieket a 5.2 kódrészlettel végzem el.

```

1 hsv = cv2.cvtColor(image, cv2.COLOR_BGR2HSV)
2
3 lower_green = np.array([40, 190, 50])
4 upper_green = np.array([65, 255, 225])
5
6 mask = cv2.inRange(hsv, lower_green, upper_green)
7
8 result = cv2.bitwise_and(image, image, mask = mask)

```

## 5.2. kódrészlet. A játékterület maszkolása.

A 5.2 kódrészletben az `image` a bemeneti kép, amelyet a `cv2.cvtColor` függvényel [12] konvertálók át HSV formátumra. Ennek a függvénynek az első paramétere a bemeneti kép, a második pedig a konverzió típusa, amely ebben az esetben  $\text{BGR} \rightarrow \text{HSV}$ .

A BGR értékekből a HSV értékek kiszámolásához először az értéket (Value) kell kiszámolni, ez a 5.1 egyenlet[12] szerint lehetséges,

$$V \leftarrow \max(R, G, B) \quad (5.1)$$

ahol  $V$  az értéket (Value) jelöli,  $R$ ,  $G$  és  $B$  pedig az adott képpont három színkomponensét (Piros, Zöld, Kék). Az egyenlet alapján az érték a három színkomponens közül a legnagyobbnak az értékét fogja felvenni. Az érték kiszámolásával megadható a telítettség (Saturation).

Ezt a 5.2 egyenlet[12] alapján lehet kiszámolni,

$$S \leftarrow \begin{cases} \frac{V - \min(R, G, B)}{V} & , \text{ha } V \neq 0 \\ 0 & , \text{különben} \end{cases} \quad (5.2)$$

itt  $S$  a telítettséget (Saturation) jelöli, és az előzőekhez hasonlóan  $V$  az értéket (Value),  $R$ ,  $G$  és  $B$  pedig a színkomponenseket, továbbá  $\min(R, G, B)$  a három színkomponens közül a legkisebbet adja meg.

Az árnyalatot (Hue) szintén az érték (Value) segítségével lehet kiszámolni, ezt a 5.3 egyenlet[12] adja meg,

$$H \leftarrow \begin{cases} \frac{60(G-B)}{V-\min(R,G,B)} & , \text{ha } V = R \\ \frac{120+60(B-R)}{V-\min(R,G,B)} & , \text{ha } V = G \\ \frac{240+60(R-G)}{V-\min(R,G,B)} & , \text{ha } V = B \\ 0 & , \text{ha } R = G = B \end{cases} \quad (5.3)$$

ahol  $H$  az árnyalatot (Hue),  $V$  az értéket (Value),  $R$ ,  $G$  és  $B$  a három színkomponens,  $\min(R, G, B)$  pedig a színkomponensek közül a minimálisat jelöli.

Amennyiben  $H$  értéke kisebb, mint 0, annak értéke  $H \leftarrow H + 360$  szerint alakul. A 8-bites és 16-bites színnel rendelkező képeknél  $R$ ,  $G$  és  $B$  értéke kezdetben normalizálásra kerül a  $[0, 1]$  intervallumba, ennek következtében a három értéknél  $0 \leq V \leq 1$ ,  $0 \leq S \leq 1$ ,  $0 \leq H \leq 360$  tartományok jelentkeznek. Az értékek visszaállítása tartománynak megfelelően 8-bites képek esetében az értékek megszerzése után  $V \leftarrow 255V$ ,  $S \leftarrow 255S$

és  $H \leftarrow H/2$  szerint megy végbe, ez hasonló 16-bites szín esetében is. 32-bites színnel rendelkező képeknél nincs kezdeti normalizálás, és ennek következtében visszaalakítás sem szükséges.[12]

Az 5.2 kódrészlethez visszatérve, a `lower_green` és `upper_green` változók az alsó és felső intenzitási határokat jelölik sorrendnek megfelelően. A maszk elkészítését a `cv2.inRange` függvénnyel [12] végzem el, itt a paraméterek sorban a HSV re konvertált kép, valamint az alsó és felső intenzitás értékek.

A függvény a 5.4 egyenlet alapján dönti el, a maszk intenzitását,

$$M(I) = L(I) \leq S(I) \leq U(I) \quad (5.4)$$

ahol  $M$  a maszk,  $L$  az alsó,  $U$  a felső és  $S$  a bemeneti HSV képet jelöli. A 5.4 függvény minden három intenzitásra alkalmazásra kerül, a maszkban az intervallumon belüli intenzitások 255, a kívüliek pedig 0 értéket kapnak. A maszk elkészítése után a maszkolás megtörténik az eredeti bemenő képre a `cv2.bitwise_and` függvény [12] segítségével. Itt a paraméterek a bejövő eredeti kép `image` kétszer és a maszk `mask`.

A folyamat során a metódus a 5.5 egyenlet szerint jár el,

$$R(I) = S_1(I) \wedge S_2(I), \text{ha } M(I) \neq 0 \quad (5.5)$$

ahol  $R$  a kimenő maszkolt kép (`result`)  $S_1$  és  $S_2$  a két bemeneti kép paraméter, és  $M$  a maszk. A bemenetben a kép azért szerepel kétszer egymás után, mert a 5.5 függvényben láthatóan a két bemenő paraméter között egy bit szintű 'és' művelet történik, amennyiben a maszk nem nulla. Ennek eredményeképp az eredeti kép adódik vissza amelyen maszkolt képpontok feketével szerepelnek. Ez azért történik, mert bit szinten ha két megegyező elem között történik 'és' művelet, akkor az eredmény szintén megegyezik a két elemmel. Ennek a folyamatnak a kimenetele látható a már előzőleg tárgyalta 4.3 ábrán.

A maszkolt kép megszerzése után elvégezhető az éldetektálás, amelyet megelőz egy szürkeárnyalatolás.

```

1 image_gray = cv2.cvtColor(result, cv2.COLOR_BGR2GRAY)
2
3 edges = cv2.Canny(image_gray, 100, 200)

```

### 5.3. kódrészlet. Szürkeárnyalatolás és éldetektálás.

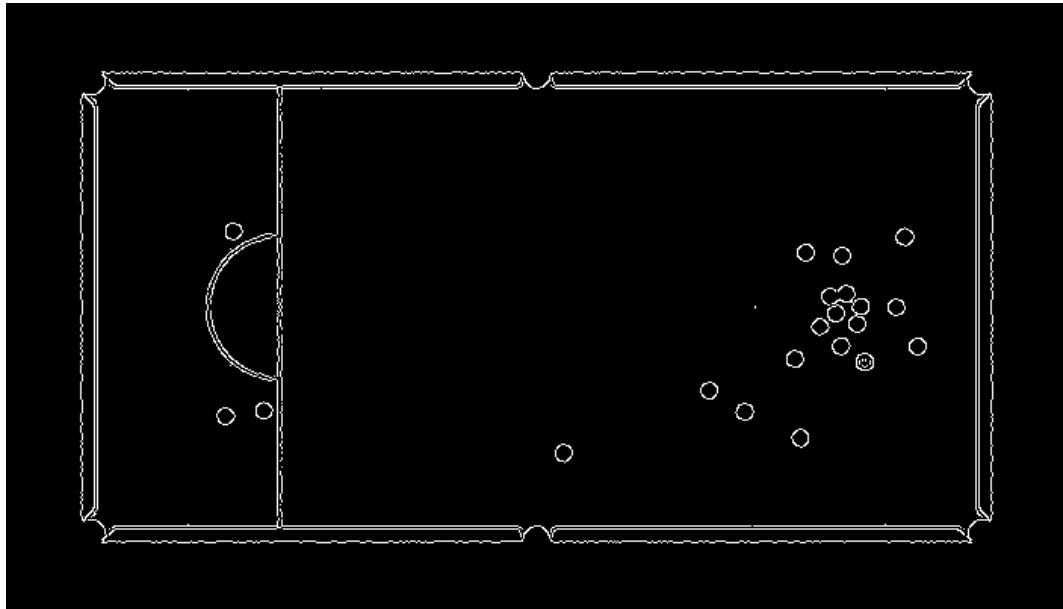
A szürkeárnyalati konverziót a már megismert `cv2.cvtColor` függvénnyel [12] végzem el a 5.3 kódrészlet alapján, majd ezután megkeressem az éleket a képen Canny éldetektálás [12, 6] (`cv2.Canny`) segítségével.

A Canny éldetektálás általában több lépésre bontható szét, ezek lehetnek:

- homályosítás Gauss szűrővel [15] a zajcsökkentés érdekében,
- élek helyének és irányának megállapítása intenzitás-gradiensből,
- nem-maximum vágás merőleges élek szűréshéhez,
- kettős küszöbölés élek szűréséhez.

Az éldetektálásnál meg kell adni a függvénynek a szürkeárnyalatos képet (`image_gray`), továbbá két küszöbertéket, amelyet a Canny detektálás a kettős küszöbölés folyamat során fog felhasználni. Itt, ha a felső küszöb felett van egy potenciális él, az hozzáadódik az élek közé, ha az alsó küszöb alatt van eldobódik és ha a felső és alsó küszöbök között helyezkedik el, akkor a szomszédos pixelek alapján kerül az élek közé. Az éldetektálással kapott kép (`edges`) a 5.1 ábrán látható.

A következő lépésben a bináris képen lefuttatásra kerül egy kontúrkereső algoritmus [16], majd a kapott kontúroknek vesszem a konvex körfonalát, azok egyszerűsítése, eset-



**5.1. ábra.** A Canny éldetektálás után kapott kép.

leges konkáv alakzatok megszüntetése érdekében. Ezek után feltételezve, hogy a kontúrok közül a legnagyobb a játékterület, az kiválasztható a körvonalak közül.

```

1 contours, _ = cv2.findContours(edges, cv2.RETR_LIST, cv2.CHAIN_APPROX_SIMPLE)
2
3 contours = [cv2.convexHull(c) for c in contours]
4 contours = sorted(contours, key=lambda x : cv2.contourArea(x), reverse=True)[:1]
```

#### 5.4. kód részlet. Kontúrok keresése.

A 5.4 kód részletben található `cv2.findContours` függvény [12, 16] egy határkövetéses algoritmussal kigyűjti a kontúrokat. Ezek a kontúrok a képen található képpont koordináták láncolatából állnak össze. A kontúrok körvonala a `cv2.convexHull` függvény [12, 14] segítségével kapható meg. Ez az algoritmus a kontúrok koordinátáinak láncolatát használja, majd a kontúrt egy konvex körvonallal határolja, ugyancsak koordináták láncolatai formájában reprezentálva.

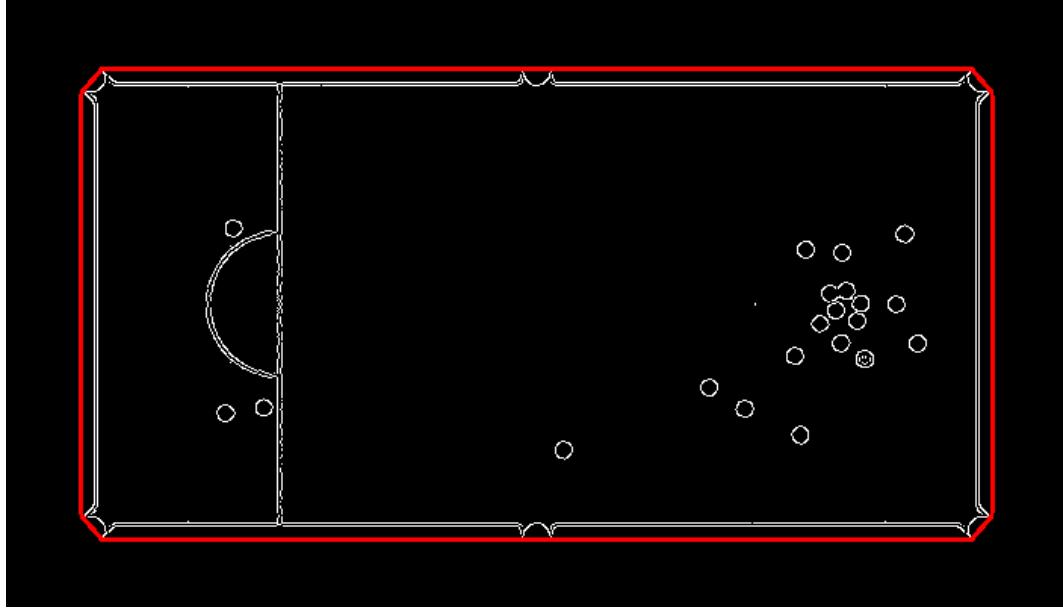
A fenti művelet elsőre feleslegesnek tűnhet, hiszen a keresett asztal kontúrja előre-láthatólag nem konkáv, a művelet elvégzése mégis fontos, hiszen így egyszerűsíthető az alakzat (kontúr koordináta láncolat pontjainak csökkentése), ezzel a folytatónak műveleteket felgyorsítva.

A legnagyobb kontúr kiválasztásához tudni kell az egyes kontúrok területét. A területet a `cv2.contourArea` függvénnyel [12] lehet kiszámolni. Ez megtehető minden eddig kontúr esetében függvénynek való paraméterkénti átadással. A kiszámolt területek közül a legnagyobbat kiválasztva, annak kontúr koordináta láncolata eltárolásra kerül. A kapott kontúr kirajzolva a 5.2 ábrán látható.

A `cv2.contourArea` függvény a Surveyor's Area algoritmust [3] használja az alakzatok területének számolásához. Ez az algoritmus a Green-tétel egy speciális esete, amely alkalmazható egyszerű sokszögekre.

Az algoritmus a 5.6 egyenletben látható,

$$A = \sum_{k=0}^n \frac{(x_{k+1} + x_k)(y_{k+1} - y_k)}{2} \quad (5.6)$$



**5.2. ábra.** A felismert asztal kontúrja a bináris képen, piros körvonalal keretezve.

ahol  $n$  az óramutató járásával ellentétesen rendezett kontúr koordináták száma,  $(x_k, y_k)$  a  $k$  adik koordináta  $x$  és  $y$  pozíciója, és feltételezhető, hogy a  $k = n + 1$  elem megegyezik a  $k = 0$  elemmel.

A 5.2 ábrán látható, hogy a kontúr téglalaphoz hasonló alakjának ellenére több, mint 4 pontból áll. Ahhoz hogy téglalap formájában legyen kivágva a kép, meg kell keresni azt a négyzetet, amely a kontúrt határolja. Erre egy olyan algoritmust készítettem, amely megkeresi a kontúr koordináták segítségével a négy leghosszabb oldalt, majd kiszámolja ezek metszéspontját. A négy leghosszabb oldal használata feltételezi, hogy a kép közel felső nézetből készült az asztalról, továbbá, hogy a sarkoknál jelenik meg több pont a kontúr keresés után.

Az oldalhosszok számolása a 5.7 képlet alapján megy végbe,

$$D = \sqrt{(x_a - x_b)^2 + (y_a - y_b)^2} \quad (5.7)$$

ahol  $D$  a kiszámolt pontok közti távolság,  $(x_a, y_a)$  és  $(x_b, y_b)$  pedig a két koordináta, amelyek között a táv számolandó. Miután megvannak az oldalak hosszai, eltárolásra kerül a négy legnagyobb oldalhoz tartozó koordináta. A kiválasztott pontoknál fontos, hogy óramutató járásával ellentétes sorrendben legyenek rendezve, amennyiben nem, a négyzet kontúr később hibás lehet.

A metszéspontok kiszámolásához a következő képleteket [17] használtam,

$$D = (x_1 - x_2)(y_3 - y_4) - (y_1 - y_2)(x_3 - x_4) \quad (5.8)$$

$$P_x = \frac{(x_1 y_2 - y_1 x_2)(x_3 - x_4) - (x_3 y_4 - y_3 x_4)(x_1 - x_2)}{D} \quad (5.9)$$

$$P_y = \frac{(x_1 y_2 - y_1 x_2)(y_3 - y_4) - (x_3 y_4 - y_3 x_4)(y_1 - y_2)}{D} \quad (5.10)$$

ahol a 5.8 képletben a  $D$  a 5.9 és 5.10 képletekben a nevező kiszámolásához biztosít könnyebb átláthatóságot,  $(P_x, P_y)$  a kiszámolt metszéspont,  $(x_1, y_1)$ ,  $(x_2, y_2)$ ,  $(x_3, y_3)$  és

$(x_4, y_4)$  pedig a négy pont, amelyek a két egyenest határozzák meg, itt ezek közül az első kettő az egyik, a második kettő a másik egyeneshez tartozik.

A fenti egyenletek megvalósítása a 5.5 kódrészletben látható,

```

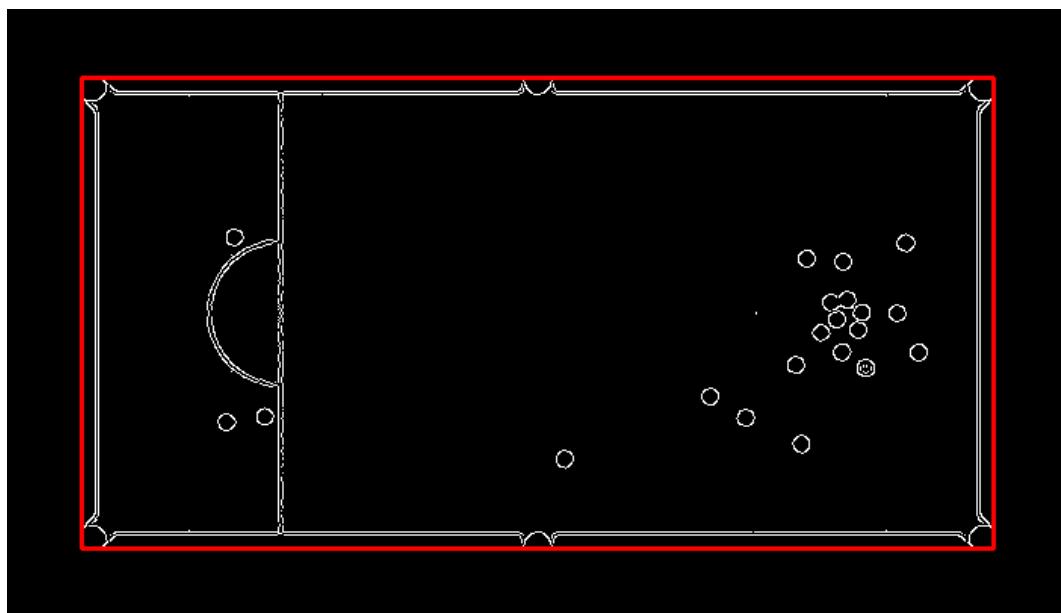
1 def intersection(p1, p2, p3, p4):
2     d = (p1[0] - p2[0]) * (p3[1] - p4[1]) - (p1[1] - p2[1]) * (p3[0] - p4[0])
3     if (abs(d) < 1e-8):
4         return False
5
6     t1 = (p1[0]*p2[1] - p1[1]*p2[0]) * (p3[0] - p4[0]) - (p3[0]*p4[1] - p3[1]*p4[0]) * (p1[0] - p2[0])
7     t2 = (p1[0]*p2[1] - p1[1]*p2[0]) * (p3[1] - p4[1]) - (p3[0]*p4[1] - p3[1]*p4[0]) * (p1[1] - p2[1])
8     return [t1 / d, t2 / d]

```

**5.5. kódrészlet.** Metszéspont kereső algoritmus.

ahol  $p_1, p_2, p_3, p_4$  a fent megismert négy koordináta,  $d$  a kiszámolt nevező,  $t_1$  és  $t_2$  pedig segédváltozók a számlálók tárolásához. A kódrészlet 3. és 4. sorában látható, hogy abban az esetben ha  $d$  nagyon kicsi, a függvény `False` értéket ad vissza. Ez azért van, mert a 5.8 függvényben kiszámolt nevező,  $D = 0$  esetén a két egyenes párhuzamos.

A folyamat végeredményeképp kapott kép a 5.3 ábrán látható.



**5.3. ábra.** A felismert asztal négy pontból álló körfonal a bináris képen, piros körfonalall keretezve.

### 5.2.3. Az asztal kivágása és torzítása

Ahhoz, hogy az asztal a kontúr segítségével kivágható legyen a képből, szükség lesz egy téglalapra, amely alapján a kivágás elvégezhető. Ebben a részben ennek a folyamatnak a működéséről fogok beszélni.

A folyamat első részeként a kapott, négy koordinátából álló kontúr pontjait rendezni kell. A pontokat bal felső, jobb felső, jobb alsó és bal alsó pontok szerint kell sorba rendezni. Az átrendezéshez a 5.6 kódot használom,

```

1 pts = contour.reshape(4, 2)
2 src = np.zeros((4, 2), "float32")
3
4 sums = pts.sum(axis=1)
5 diffs = np.diff(pts, axis=1).flatten()
6
7 src[0] = pts[np.argmin(sums)]
8 src[1] = pts[np.argmin(diffs)]
9 src[2] = pts[np.argmax(sums)]
10 src[3] = pts[np.argmax(diffs)]

```

### 5.6. kódrészlet. Átrendező algoritmus.

ahol először az első két sorban rendezem a koordináta pontokat a `pts` változóba és készíték egy `src` tömböt a rendezett adatok tárolásához. A következő lépésekben, ahhoz, hogy meg tudjam állapítani a pontok relatív helyzetét, készíték az egyes pontokból összegeket (`sums`) és különbségeket (`diffs`), amelyek az egyes koordináták  $x$  és  $y$  összetevőinek összegeiből vagy különbségeiből állnak. Ezekből az összegek és különbségekből megállapítható a pontok helyzete, tehát például a bal felső koordinátát az összegek közül a legkisebb érték, a bal alsót a különbségek közül a legnagyobb érték határozza meg, és így a többi koordinátát is. A fent említett műveletek a kódrészlet 7 - 10 soraiban láthatóak.

Az előző művelet után a sorba rendezett koordináták meghatározzák a transzformációhoz szükséges mátrix kiszámításához a forrás (`src`) értékeit. A transzformációhoz szükség van még a célértékekre is.

A célértékek a 5.7 kód soraival adhatóak meg,

```

1 width, height = (size[0] - 1, size[1] - 1)
2
3 dst = np.array([
4     [0, 0],
5     [width, 0],
6     [width, height],
7     [0, height]],
8     dtype="float32")

```

### 5.7. kódrészlet. A kimeneti értékek megadása.

itt a cél kép méretei egy érték páros formájában szerepelnek a `size` változóban, ezek szélesség és magasság elemekre bomlanak a `width` és `height` változókban. Az értékekből egyet való levonás az indexelés végett szükséges. A szélesség és magasság értékkkel ezután meg lehet adni a célértékeket a transzformációs mátrix elkészítéséhez, ezek a `dst` változóba kerülnek.

A transzformáció végrehajtásához mindezek után már csak a transzformációs mátrix elkészítésére van szükség, majd a transzformáció végrehajtására.

Ezek a 5.8 kódrészlettel hajthatóak végre,

```

1 M = cv2.getPerspectiveTransform(src, dst)
2 warp = cv2.warpPerspective(image, M, size)

```

### 5.8. kódrészlet. A transzformáció végrehajtása.

itt `M` a transzformációs mátrix, amely a `cv2.getPerspectiveTransform` függvénnyel [12] kaptható meg a forrás és célértékek megadásával. A függvény Gauss-elimináció [9] segítségével számol ki egy  $3 \times 3$  méretű mátrixot, amelyet a `cv2.warpPerspective` függvénnyel [12] alkalmazok az `image` változóban tárolt képre az `M` mátrix és `size` méret megadásával. A transzformáló függvény lineáris interpolációt [2] használ alapértelmezett esetben az intenzitás értékek meghatározásához.

A kivágott és torzított kép a már megismert 4.4 ábrán látható.

#### 5.2.4. Körkeresés és azonosítás

A körök detektálásához az ún. Hough transzformációt (Hough Transformation) fogom használni, ez a H.K. Yuen, J. Princen, J. Illingworth és J. Kittler et. al. 1990 [19] szerint abban az esetben, ha egy kör a kövekező 5.11 függvényel írható le,

$$(x - a)^2 + (y - b)^2 = r^2 \quad (5.11)$$

ahol  $a$  és  $b$  a kör középpontjának koordinátái és  $r$  a sugár, akkor a körvonal élének egy tetszőleges  $x_i, y_i$  pontja átalakításra kerül egy  $a, b, r$  paraméterek által meghatározott térből elhelyezkedő egyenes kör alapú kúppá.[7, 19] Amennyiben az adott pontok egy körvonalon helyezkednek el, a kúpok metszeti fogják egymást a kör  $a, b, r$  pontjainak megfelelően.[19]

# Irodalomjegyzék

- [1] Martín Abadi – Ashish Agarwal – Paul Barham – Eugene Brevdo – Zhifeng Chen – Craig Citro – Greg S. Corrado – Andy Davis – Jeffrey Dean – Matthieu Devin – Sanjay Ghemawat – Ian Goodfellow – Andrew Harp – Geoffrey Irving – Michael Isard – Yangqing Jia – Rafal Jozefowicz – Lukasz Kaiser – Manjunath Kudlur – Josh Levenberg – Dandelion Mané – Rajat Monga – Sherry Moore – Derek Murray – Chris Olah – Mike Schuster – Jonathon Shlens – Benoit Steiner – Ilya Sutskever – Kunal Talwar – Paul Tucker – Vincent Vanhoucke – Vijay Vasudevan – Fernanda Viégas – Oriol Vinyals – Pete Warden – Martin Wattenberg – Martin Wicke – Yuan Yu – Xiaoqiang Zheng: TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. URL <https://www.tensorflow.org/>. Software available from tensorflow.org.
- [2] T. Blu – P. Thevenaz – M. Unser: Linear interpolation revitalized. *IEEE Transactions on Image Processing*, 13. évf. (2004) 5. sz., 710–719. p.
- [3] Bart Braden: The surveyor's area formula. *The College Mathematics Journal*, 17. évf. (1986) 4. sz., 326–337. p.
- [4] G. Bradski: The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 2000.
- [5] G. Bradski – A. Kaehler: *Learning OpenCV: Computer Vision with the OpenCV Library*. 2008, O'Reilly Media. ISBN 9780596554040.  
URL <https://books.google.hu/books?id=seAgi0fu2EIC>.
- [6] John Canny: A computational approach to edge detection. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, PAMI-8. évf. (1986) 6. sz., 679–698. p.
- [7] Richard O. Duda – Peter E. Hart: Use of the hough transformation to detect lines and curves in pictures. *Commun. ACM*, 15. évf. (1972. jan) 1. sz., 11–15. p. ISSN 0001-0782. URL <https://doi.org/10.1145/361237.361242>. 5 p.
- [8] Snooker játék. URL <http://www.flyordie.hu/snooker/>.
- [9] Joseph F Grcar: Mathematicians of gaussian elimination. *Notices of the AMS*, 58. évf. (2011) 6. sz., 782–792. p.
- [10] Introduction to gradients and automatic differentiation.  
URL <https://www.tensorflow.org/guide/autodiff>.
- [11] A. Kaehler – G. Bradski: *Learning OpenCV 3: Computer Vision in C++ with the OpenCV Library*. 2016, O'Reilly Media. ISBN 9781491938003.  
URL <https://books.google.hu/books?id=SKy3DQAAQBAJ>.
- [12] Opencv dokumentáció. URL <https://docs.opencv.org/4.5.0/>.

- [13] M.I. Shamos: *The New Illustrated Encyclopedia of Billiards*. G - Reference, Information and Interdisciplinary Subjects Series sorozat. 2002, Lyons Press. ISBN 9781585746859. URL <https://books.google.hu/books?id=B02BAAAAMAAJ>.
- [14] Jack Sklansky: Finding the convex hull of a simple polygon. *Pattern Recognition Letters*, 1. évf. (1982) 2. sz., 79–83. p. ISSN 0167-8655. URL <https://www.sciencedirect.com/science/article/pii/0167865582900162>.
- [15] George Stockman – Linda G. Shapiro: *Computer Vision*. Upper Saddle River, NJ, USA, 2001, Prentice Hall PTR, 166. p. ISBN 0130307963.
- [16] Satoshi Suzuki – Keiichi A be: Topological structural analysis of digitized binary images by border following. *Computer Vision, Graphics, and Image Processing*, 30. évf. (1985) 1. sz., 32–46. p. ISSN 0734-189X. URL <https://www.sciencedirect.com/science/article/pii/0734189X85900167>.
- [17] Weisstein & Eric W.: Line-line intersection.  
URL <https://mathworld.wolfram.com/Line-LineIntersection.html>.
- [18] WPBSA: *Official Rules of the Games of Snooker and English Billiards*. 2019, The World Professional Billiards & Snooker Association Limited. URL <https://wpbsa.com/wp-content/uploads/WPBSA-Official-Rules-of-the-Games-of-Snooker-and-Billiards-2020.pdf>.
- [19] HK Yuen – J Princen – J Illingworth – J Kittler: Comparative study of hough transform methods for circle finding. *Image and Vision Computing*, 8. évf. (1990) 1. sz., 71–77. p. ISSN 0262-8856. URL <https://www.sciencedirect.com/science/article/pii/026288569090059E>.